

**LAPORAN TUGAS PRAKTIKUM
PENGANTAR KECERDASAN BUATAN**

**DETEKSI SPAM EMAIL LAYANAN KAMPUS
MENGUNAKAN MACHINE LEARNING
(KLASIFIKASI TEKS TF-IDF DAN NAIVE BAYES)**

Bidang AI: Machine Learning

Studi Kasus: Penyaringan Spam Email pada Sistem dan Teknologi Informasi

Disusun oleh:

Abdul Aziz

NIM 2024606601040

**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
UNIVERSITAS MUHAMMADIYAH PRINGSEWU**

2026

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat-Nya laporan tugas praktikum ini dapat diselesaikan. Laporan ini disusun untuk memenuhi tugas praktikum mandiri yang bertujuan agar mahasiswa mampu mengidentifikasi bidang kecerdasan buatan (*artificial intelligence*, AI), menjelaskan karakteristiknya, serta menentukan penerapan yang relevan pada masalah Sistem dan Teknologi Informasi.

Bidang AI yang dipilih adalah *Machine Learning*, dengan studi kasus deteksi spam email pada layanan surat elektronik kampus. Laporan memuat deskripsi masalah, alasan pemilihan bidang, data yang diperlukan, cara kerja solusi, keluaran yang diharapkan, serta pembahasan manfaat, keterbatasan, dan risiko etika maupun privasi. Demonstrasi dibuat dalam bentuk *notebook* Python yang dapat dijalankan di Google Colab.

Penulis menyadari bahwa laporan ini masih memiliki keterbatasan, terutama karena data yang dipakai untuk demonstrasi merupakan data sintetis. Kritik dan saran yang membangun sangat diharapkan demi perbaikan di masa mendatang. Semoga laporan ini bermanfaat bagi pembaca.

DAFTAR ISI

BAB I PENDAHULUAN	5
1.1 Latar Belakang	5
1.2 Rumusan Masalah	6
1.3 Tujuan	6
1.4 Batasan Masalah.....	6
1.5 Manfaat	7
1.6 Sistematika Penulisan.....	7
BAB II LANDASAN TEORI	8
2.1 Kecerdasan Buatan dan Bidang-Bidanganya.....	8
2.2 Machine Learning	9
2.3 Klasifikasi Teks dan Deteksi Spam.....	9
2.4 Pra-pemrosesan Teks	10
2.5 Representasi Fitur: TF-IDF	10
2.6 Algoritma Klasifikasi	11
2.7 Metrik Evaluasi	11
2.8 Etika dan Privasi dalam AI	12
BAB III ANALISIS MASALAH DAN RANCANGAN SOLUSI	13
3.1 Deskripsi Masalah.....	13
3.2 Alasan Pemilihan Bidang AI.....	13
3.3 Data dan Masukan yang Diperlukan	14
3.4 Gambaran Cara Kerja Solusi.....	15
3.5 Keluaran yang Diharapkan.....	16
3.6 Perangkat yang Digunakan	17
3.7 Rancangan Integrasi pada Layanan Email Kampus.....	17
BAB IV IMPLEMENTASI DAN HASIL	19
4.1 Persiapan Data.....	19
4.2 Pra-pemrosesan dan Ekstraksi Fitur.....	19
4.3 Pelatihan Model	20
4.4 Hasil Evaluasi.....	20
4.5 Analisis Kesalahan	23
4.6 Demonstrasi Prediksi Email Baru	24
4.7 Diskusi Hasil dan Ancaman terhadap Validitas.....	24
4.8 Eksperimen Tambahan.....	25
4.9 Rencana Pengembangan.....	27

BAB V PEMBAHASAN MANFAAT, KETERBATASAN, DAN RISIKO ETIKA/PRIVASI	28
5.1 Manfaat	28
5.2 Keterbatasan	28
5.3 Risiko Etika dan Privasi	29
5.4 Prinsip Penerapan yang Bertanggung Jawab	29
BAB VI PENUTUP	31
6.1 Kesimpulan	31
6.2 Saran.....	31
DAFTAR PUSTAKA	32
LAMPIRAN.....	33
Lampiran 1. Tautan Proyek.....	33
Lampiran 2. Struktur Repositori	33
Lampiran 3. Kode Pembangkit Dataset (buat_dataset.py).....	33
Lampiran 4. Kode Pelatihan dan Evaluasi (deteksi_spam.py).....	34
Lampiran 5. Glosarium	37

BAB I

PENDAHULUAN

1.1 Latar Belakang

Surat elektronik (*email*) menjadi kanal komunikasi resmi di lingkungan perguruan tinggi. Pengumuman akademik, jadwal ujian, tagihan pembayaran, pemberitahuan pemeliharaan sistem, hingga korespondensi antara mahasiswa, dosen, dan tenaga kependidikan hampir seluruhnya berlangsung melalui email. Ketergantungan yang tinggi ini menjadikan email sasaran empuk bagi pengirim pesan yang tidak diinginkan (*spam*) maupun pelaku penipuan daring (*phishing*).

Spam bukan sekadar gangguan. Pesan spam memenuhi kotak masuk, menyita waktu pengguna, dan membebani penyimpanan serta lalu lintas jaringan. Lebih berbahaya lagi, sebagian spam menyamar sebagai pemberitahuan resmi, misalnya peringatan pemblokiran akun bank atau permintaan verifikasi kata sandi, untuk mencuri data pribadi. Bagi unit layanan teknologi informasi kampus, memilah pesan semacam ini secara manual tidak mungkin dilakukan karena volume email yang besar dan pola serangan yang terus berubah.

Pendekatan klasik untuk menyaring spam adalah aturan tetap (*rule-based*), misalnya memblokir email yang mengandung kata tertentu atau berasal dari alamat tertentu. Pendekatan ini mudah dipahami tetapi rapuh: pengirim spam cukup mengganti ejaan kata, dan aturan yang terlalu ketat justru memblokir email sah. Di sinilah *machine learning* menawarkan keunggulan. Alih-alih menulis aturan satu per satu, sistem belajar sendiri dari contoh email yang sudah berlabel spam atau bukan spam, lalu menggeneralisasi pola tersebut pada email baru.

Laporan ini membahas perancangan dan demonstrasi sistem sederhana pendeteksi spam berbahasa Indonesia untuk layanan email kampus. Studi kasus ini dipilih karena dekat dengan bidang Sistem dan Teknologi Informasi, datanya berupa teks yang mudah dipahami, dan hasilnya dapat dievaluasi secara kuantitatif dengan metrik yang baku.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam laporan ini adalah sebagai berikut.

1. Bagaimana karakteristik bidang *machine learning* dan mengapa bidang ini sesuai untuk masalah pendeteksian spam email?
2. Data dan tahapan pemrosesan apa yang diperlukan untuk membangun pengklasifikasi spam berbahasa Indonesia?
3. Seberapa baik kinerja model klasifikasi teks sederhana (Naive Bayes, *Logistic Regression*, dan *Linear SVM*) dalam membedakan email spam dan email sah pada data demonstrasi?
4. Apa manfaat, keterbatasan, serta risiko etika dan privasi dari penerapan sistem ini pada layanan email kampus?

1.3 Tujuan

- Mengidentifikasi bidang AI *machine learning* dan menjelaskan karakteristiknya.
- Menentukan dan mendeskripsikan studi kasus deteksi spam email yang relevan dengan Sistem dan Teknologi Informasi.
- Membangun demonstrasi pengklasifikasi spam menggunakan Python di Google Colab dan mengevaluasi kinerjanya.
- Menganalisis manfaat, keterbatasan, dan risiko etika serta privasi dari solusi yang dirancang.

1.4 Batasan Masalah

- Sistem hanya mengklasifikasikan teks email ke dalam dua kelas: *spam* dan *ham* (email sah). Lampiran, gambar, dan *header* email tidak dianalisis.
- Data demonstrasi berupa 3.000 email sintetis berbahasa Indonesia yang dibuat sendiri, bukan email nyata, demi menjaga privasi.
- Model yang dibandingkan terbatas pada tiga algoritma klasik: Multinomial Naive Bayes, *Logistic Regression*, dan *Linear Support Vector Machine*.
- Demonstrasi tidak mencakup penerapan langsung pada server email; fokus pada prototipe di lingkungan *notebook*.

1.5 Manfaat

Bagi mahasiswa, tugas ini melatih kemampuan memetakan masalah dunia nyata ke bidang AI yang tepat, menyiapkan data, membangun model, dan mengevaluasinya. Bagi pembaca dan pengelola layanan TI, laporan ini memberi gambaran awal tentang bagaimana *machine learning* dapat dipakai untuk mengurangi beban penyaringan email, sekaligus mengingatkan pada batasan dan risikonya.

1.6 Sistematika Penulisan

Laporan terdiri atas enam bab. Bab I berisi pendahuluan. Bab II memaparkan landasan teori tentang AI, *machine learning*, klasifikasi teks, dan metrik evaluasi. Bab III menjelaskan deskripsi masalah, alasan pemilihan bidang, data, dan rancangan solusi. Bab IV menyajikan implementasi dan hasil percobaan. Bab V membahas manfaat, keterbatasan, serta risiko etika dan privasi. Bab VI memuat kesimpulan dan saran. Kode program dilampirkan pada bagian akhir.

BAB II

LANDASAN TEORI

2.1 Kecerdasan Buatan dan Bidang-Bidanganya

Kecerdasan buatan adalah cabang ilmu komputer yang mempelajari cara membangun sistem yang mampu melakukan tugas yang biasanya membutuhkan kecerdasan manusia, seperti memahami bahasa, mengenali pola, mengambil keputusan, dan belajar dari pengalaman (Russell & Norvig, 2020). AI bukan satu teknik tunggal, melainkan payung bagi banyak bidang dengan karakter yang berbeda. Beberapa bidang yang lazim dibahas adalah *machine learning*, *deep learning*, pemrosesan bahasa alami, *computer vision*, sistem pakar, logika *fuzzy*, pencarian dan optimasi, sistem rekomendasi, agen cerdas, serta robotika dan sistem otonom.

Tabel 1. Ringkasan bidang AI dan contoh penerapan pada Sistem dan Teknologi Informasi

Bidang AI	Ciri utama	Contoh masalah TI
Machine Learning	Belajar pola dari data berlabel atau tak berlabel	Deteksi spam, prioritas tiket layanan
Deep Learning	Jaringan saraf berlapis banyak, butuh data besar	Klasifikasi gambar, model bahasa besar
Natural Language Processing	Memahami dan menghasilkan bahasa manusia	Chatbot layanan akademik
Computer Vision	Menafsirkan citra dan video	Pengenalan pelat nomor parkir
Sistem Pakar	Aturan pengetahuan dari pakar (JIKA-MAKA)	Diagnosis gangguan jaringan
Logika Fuzzy	Derajat keanggotaan, penalaran tidak pasti	Kontrol suhu ruang server
Pencarian dan Optimasi	Mencari solusi terbaik dalam ruang kemungkinan	Penjadwalan mata kuliah
Sistem Rekomendasi	Menyarankan item sesuai preferensi	Rekomendasi mata kuliah
Agen Cerdas	Mempersepsi lingkungan dan bertindak otonom	Asisten penjadwalan otomatis
Robotika dan Sistem Otonom	Perangkat fisik yang bergerak dan mengambil keputusan	Robot pengantar, parkir cerdas

2.2 Machine Learning

Machine learning (ML) adalah bidang AI yang membuat komputer belajar dari data tanpa diprogram secara eksplisit untuk setiap aturan. Sebuah program dikatakan belajar dari pengalaman E terhadap tugas T dengan ukuran kinerja P apabila kinerjanya pada T , yang diukur dengan P , meningkat seiring bertambahnya E . Pada studi kasus ini, tugas T adalah mengklasifikasikan email, pengalaman E adalah kumpulan email berlabel, dan ukuran kinerja P adalah akurasi, presisi, *recall*, dan F1.

2.2.1 Jenis pembelajaran

- **Pembelajaran terawasi (*supervised learning*):** model belajar dari pasangan masukan dan label. Klasifikasi spam termasuk jenis ini.
- **Pembelajaran tak terawasi (*unsupervised learning*):** model mencari struktur pada data tanpa label, misalnya pengelompokan (*clustering*).
- **Pembelajaran penguatan (*reinforcement learning*):** agen belajar melalui percobaan dan imbalan dari lingkungan.

2.2.2 Karakteristik machine learning

- **Berbasis data.** Kualitas model sangat ditentukan oleh kualitas, jumlah, dan keterwakilan data latih.
- **Bersifat probabilistik.** Keluaran berupa perkiraan dengan tingkat keyakinan, bukan kepastian; kesalahan tidak dapat dihilangkan sepenuhnya.
- **Adaptif.** Model dapat dilatih ulang ketika pola baru muncul, misalnya modus spam baru.
- **Bergantung pada representasi fitur.** Untuk teks, cara mengubah kata menjadi angka menentukan kemampuan model.

2.3 Klasifikasi Teks dan Deteksi Spam

Klasifikasi teks adalah tugas menetapkan satu atau beberapa kategori pada suatu dokumen teks. Deteksi spam merupakan klasifikasi biner: setiap email dimasukkan ke kelas *spam* atau *ham*. Penyaring spam berbasis statistik sudah diteliti sejak akhir 1990-an, salah satunya pendekatan Bayesian yang menghitung

peluang sebuah pesan sebagai spam berdasarkan kata-kata yang dikandungnya (Sahami dkk., 1998). Sejak itu, klasifikasi teks dengan fitur kata dan model linear terbukti menjadi *baseline* yang kuat dan efisien untuk penyaringan pesan (Almeida dkk., 2011).

2.4 Pra-pemrosesan Teks

Teks mentah tidak dapat langsung diolah algoritma ML, sehingga perlu dibersihkan dan dinormalisasi. Tahapan yang dipakai dalam laporan ini adalah sebagai berikut.

1. **Perubahan ke huruf kecil (*case folding*)** agar "Segera" dan "segera" dianggap sama.
2. **Penggantian tautan** dengan token khusus *tautan*, sebab alamat URL spam berubah-ubah tetapi keberadaan tautan itu sendiri merupakan sinyal penting.
3. **Penggantian angka** dengan token *angka*, agar nominal uang atau persentase tertentu tidak menjadi fitur yang terlalu spesifik.
4. **Penghapusan tanda baca dan simbol** yang tidak membawa makna kata.
5. **Tokenisasi**, yakni memecah kalimat menjadi kata atau gabungan kata (*n-gram*).

2.5 Representasi Fitur: TF-IDF

Term Frequency–Inverse Document Frequency (TF-IDF) memberi bobot pada setiap kata dalam sebuah dokumen. Bobot tinggi diberikan pada kata yang sering muncul di dokumen tersebut (TF) tetapi jarang muncul di seluruh koleksi dokumen (IDF), sehingga kata umum seperti "yang" atau "dan" memiliki bobot rendah, sedangkan kata pembeda seperti "undian" memiliki bobot tinggi (Manning dkk., 2008). Secara sederhana, bobot kata t pada dokumen d adalah $tf(t,d) \times idf(t)$, dengan $idf(t) = \log(N / df(t)) + 1$ pada varian yang dipakai *scikit-learn*, di mana N adalah jumlah dokumen dan $df(t)$ adalah jumlah dokumen yang memuat t .

Laporan ini memakai unigram dan bigram (*ngram_range* = (1,2)) sehingga frasa seperti "akun diblokir" atau "klik tautan" ditangkap sebagai satu fitur. Kata yang muncul pada kurang dari dua dokumen dibuang (*min_df* = 2) untuk

mengurangi *noise*, dan digunakan *sublinear TF* ($1 + \log \text{tf}$) agar kata yang berulang banyak kali tidak mendominasi.

2.6 Algoritma Klasifikasi

2.6.1 Multinomial Naive Bayes

Naive Bayes menerapkan teorema Bayes dengan asumsi "naif" bahwa setiap kata bersifat saling bebas jika kelas diketahui. Untuk sebuah email dengan kata $w_1, \dots, w_n$, kelas yang dipilih adalah kelas c yang memaksimalkan $P(c) \times \prod P(w_i | c)$. Meskipun asumsi kebebasan jarang benar pada bahasa alami, algoritma ini cepat, membutuhkan data relatif sedikit, dan sudah lama menjadi andalan penyaring spam. Parameter penghalusan Laplace (*alpha*) diatur 0,5 agar kata yang belum pernah muncul di suatu kelas tidak membuat peluang menjadi nol.

2.6.2 Logistic Regression

Logistic Regression memodelkan peluang sebuah email adalah spam sebagai fungsi sigmoid dari kombinasi linear fitur, $P(\text{spam} | x) = 1 / (1 + e^{-(w \cdot x + b)})$. Bobot w dipelajari dengan meminimalkan galat log-loss disertai regularisasi. Setiap bobot dapat ditafsirkan: bobot positif besar berarti kata tersebut mendorong prediksi ke arah spam. Sifat ini membuat model mudah dijelaskan kepada pengguna dan auditor.

2.6.3 Linear Support Vector Machine

Support Vector Machine (SVM) linear mencari *hyperplane* yang memisahkan dua kelas dengan margin terbesar. Pada ruang fitur teks yang berdimensi tinggi dan jarang (*sparse*), SVM linear sering memberi hasil sangat baik dan pelatihan yang cepat. Berbeda dengan dua model sebelumnya, SVM secara bawaan tidak menghasilkan peluang, melainkan jarak ke *hyperplane*.

2.7 Metrik Evaluasi

Kinerja pengklasifikasi biner diringkas dalam *confusion matrix* yang memuat empat nilai: *true positive* (TP, spam terdeteksi spam), *true negative* (TN, ham terdeteksi ham), *false positive* (FP, ham salah dideteksi spam), dan *false negative* (FN, spam lolos sebagai ham). Dari keempat nilai ini diturunkan metrik berikut.

Tabel 2. Metrik evaluasi klasifikasi biner

Metrik	Rumus	Makna pada deteksi spam
Accuracy	$(TP + TN) / (TP + TN + FP + FN)$	Proporsi email yang diklasifikasikan benar
Precision	$TP / (TP + FP)$	Dari semua email yang dicap spam, berapa yang benar-benar spam
Recall	$TP / (TP + FN)$	Dari semua spam yang ada, berapa yang berhasil tertangkap
F1-score	$2 \times P \times R / (P + R)$	Rata-rata harmonik precision dan recall

Pada penyaringan email, kedua jenis kesalahan tidak setara. *False positive* (email sah masuk karantina) sering lebih merugikan daripada *false negative* (satu spam lolos), sebab pengguna dapat kehilangan pengumuman penting. Karena itu presisi dan *recall* dilaporkan terpisah, tidak hanya akurasi. Selain pembagian data latih dan uji, dipakai *stratified 5-fold cross-validation* untuk menaksir kestabilan kinerja model.

2.8 Etika dan Privasi dalam AI

Sistem yang membaca isi surat elektronik menyentuh data pribadi. Di Indonesia, pemrosesan data pribadi diatur dalam Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi, yang antara lain menekankan tujuan yang sah, pembatasan tujuan, dan keamanan pemrosesan. Prinsip umum etika AI seperti keadilan, transparansi, akuntabilitas, dan pengawasan manusia juga relevan, dan dibahas lebih lanjut pada Bab V.

BAB III

ANALISIS MASALAH DAN RANCANGAN SOLUSI

3.1 Deskripsi Masalah

Layanan email kampus menerima ribuan pesan setiap hari. Sebagian di antaranya adalah pesan yang tidak diminta: penawaran pinjaman online, undian berhadiah palsu, promosi judi daring, hingga *phishing* yang menyamar sebagai bank atau pihak kampus. Pesan-pesan ini menimbulkan tiga masalah utama.

1. **Keamanan.** Mahasiswa dan staf dapat tertipu memberikan kata sandi atau data rekening, yang berujung pada pengambilalihan akun dan kerugian finansial.
2. **Produktivitas.** Email penting, seperti pengumuman ujian atau tagihan UKT, tenggelam di antara spam sehingga terlewat.
3. **Beban layanan TI.** Tim helpdesk kewalahan menangani laporan pengguna tentang email mencurigakan, sementara aturan penyaring manual harus terus diperbarui.

Masalah inti yang diselesaikan adalah: *bagaimana memilah secara otomatis email masuk menjadi spam dan email sah dengan akurasi tinggi, dengan tetap menekan jumlah email sah yang keliru dicap spam.*

3.2 Alasan Pemilihan Bidang AI

Machine learning dipilih karena karakter masalahnya sangat cocok dengan kekuatan bidang ini. Pertimbangan pemilihannya diuraikan pada Tabel 3.

Tabel 3. Alasan pemilihan machine learning untuk deteksi spam

Pertimbangan	Penjelasan
Pola sulit ditulis sebagai aturan	Variasi kata, ejaan, dan gaya spam terlalu banyak untuk dirangkum dalam daftar aturan JIKA-MAKA yang stabil.
Data berlabel dapat dikumpulkan	Pengguna dapat menandai email sebagai spam, sehingga label tersedia secara alami untuk pelatihan.
Pola berubah dari waktu ke waktu	Model dapat dilatih ulang dengan data baru, sedangkan aturan tetap harus ditulis ulang manual.
Keluaran berupa kategori	Tugas berbentuk klasifikasi biner, formulasi yang matang dan metrik evaluasinya baku.
Biaya komputasi rendah	Model linear berbasis TF-IDF dilatih dalam hitungan detik dan cukup ringan untuk server kampus.
Dapat dijelaskan	Kata yang paling berpengaruh dapat ditampilkan sehingga keputusan model bisa diaudit.

Bidang lain dipertimbangkan tetapi kurang sesuai sebagai pilihan utama. Sistem pakar dan logika *fuzzy* membutuhkan aturan yang disusun manual sehingga sulit mengikuti perubahan modus spam. *Deep learning* dan NLP berbasis model bahasa besar mungkin memberi akurasi lebih tinggi pada teks yang kompleks, tetapi membutuhkan data dan sumber daya jauh lebih besar serta lebih sulit dijelaskan, padahal untuk data demonstrasi ini pendekatan klasik sudah memadai. Bidang lain seperti *computer vision*, robotika, dan sistem rekomendasi tidak relevan dengan data berupa teks email.

3.3 Data dan Masukan yang Diperlukan

Masukan sistem adalah teks email (subjek dan badan pesan) yang digabung menjadi satu string. Untuk pelatihan diperlukan kumpulan email dengan label *spam* atau *ham*. Pada sistem produksi, sumber label dapat berupa laporan pengguna, keputusan administrator, atau data historis penyaring lama.

Karena email nyata memuat data pribadi, demonstrasi pada laporan ini menggunakan **dataset sintetis** yang dibuat dengan skrip *buat_dataset.py*. Dataset dirancang sedemikian rupa agar memuat tantangan yang mirip kondisi nyata.


- **Spam** mencakup sepuluh modus: *phishing* bank, undian palsu, pinjaman online, judi daring, investasi bodong, lowongan kerja palsu, paket tertahan, obat herbal, login mencurigakan, dan hadiah gawai.
- **Ham** mencakup dua belas jenis email kampus: jadwal ujian, tiket layanan TI, tugas dosen, undangan rapat, pengumuman verifikasi KRS, seminar gratis, diskon toko buku kampus, obrolan antarmahasiswa, pemeliharaan sistem, pembayaran UKT, notifikasi keamanan, dan penerimaan laporan.
- **Kasus sulit.** Email ham sengaja memuat kata yang lazim di spam ("gratis", "diskon", "verifikasi", "segera"), dan sebagian spam diawali kalimat netral.
- **Noise label 2%.** Sebanyak 2% label dibalik secara acak untuk meniru kesalahan pelabelan manusia.

Tabel 4. Ringkasan dataset sintetis

Keterangan	Nilai
Jumlah email	3.000
Spam / Ham	1.074 / 1.926
Data latih / data uji (80% / 20%)	2.400 / 600
Rata-rata panjang teks	19,7 kata
Jumlah fitur TF-IDF (unigram + bigram)	1.144

3.4 Gambaran Cara Kerja Solusi

Solusi bekerja dalam dua fase. Pada fase *pelatihan*, kumpulan email berlabel dibersihkan, diubah menjadi vektor TF-IDF, lalu dipakai untuk melatih model klasifikasi. Pada fase *inferensi*, email baru melewati pembersihan dan vektorisasi yang sama, kemudian model menghasilkan label dan, bila tersedia, skor peluang spam. Email yang dinyatakan spam dipindahkan ke karantina, bukan dihapus, agar pengguna masih dapat meninjaunya.



Gambar 1. Alur kerja sistem deteksi spam email

1. **Pengumpulan data:** email berlabel spam atau ham dikumpulkan (di sini dibuat secara sintetis).
2. **Pra-pemrosesan:** huruf kecil, penggantian tautan dan angka, penghapusan simbol.
3. **Ekstraksi fitur:** TF-IDF dengan unigram dan bigram.
4. **Pelatihan:** tiga model dilatih pada 80% data dan diuji pada 20% data yang belum pernah dilihat.
5. **Evaluasi:** accuracy, precision, recall, F1, *confusion matrix*, dan *cross-validation*.
6. **Penerapan:** model terbaik dipakai memprediksi email baru dan hasilnya dikarantina bila terklasifikasi spam.

3.5 Keluaran yang Diharapkan

- Label prediksi untuk setiap email: *spam* atau *ham*.
- Skor peluang spam (untuk model yang mendukung), sehingga pengelola dapat mengatur ambang batas karantina.
- Laporan evaluasi: metrik, *confusion matrix*, dan daftar kata penciri.
- Daftar email yang salah klasifikasi untuk ditinjau manusia dan dipakai memperbaiki data.

3.6 Perangkat yang Digunakan

Tabel 5. Perangkat dan pustaka yang digunakan

Perangkat	Fungsi
Google Colab / Python 3	Lingkungan menjalankan notebook demonstrasi
pandas, NumPy	Pengolahan data tabular dan numerik
scikit-learn	TF-IDF, model klasifikasi, dan metrik evaluasi (Pedregosa dkk., 2011)
matplotlib	Visualisasi grafik dan confusion matrix
GitHub	Penyimpanan kode, data, laporan, dan slide

3.7 Rancangan Integrasi pada Layanan Email Kampus

Prototipe pada laporan ini berjalan di *notebook*. Agar dapat dipakai pada layanan email kampus, model perlu dipasang sebagai salah satu komponen dalam jalur penerimaan email. Rancangan yang diusulkan bersifat berlapis: penyaring cepat berbasis aturan dan reputasi menyaring pesan yang jelas berbahaya, lalu model *machine learning* menilai sisanya, dan keputusan akhir bergantung pada skor.

1. **Penerimaan.** Server email (MTA) menerima pesan dan memeriksa autentikasi pengirim (SPF, DKIM, DMARC) serta daftar hitam alamat dan domain yang sudah diketahui.
2. **Ekstraksi teks.** Subjek dan badan pesan diambil, tautan diekstrak, dan teks dibersihkan dengan fungsi pra-pemrosesan yang sama seperti saat pelatihan.
3. **Penilaian model.** Layanan kecil (misalnya API internal) menerima teks dan mengembalikan skor peluang spam.
4. **Keputusan.** Skor di bawah ambang batas bawah diteruskan ke kotak masuk; skor di atas ambang batas atas dikarantina; skor di antaranya diberi peringatan pada pesan dan ditandai untuk ditinjau.
5. **Umpan balik.** Tombol "laporkan spam" dan "bukan spam" menyimpan koreksi pengguna sebagai data pelatihan berikutnya, dengan pemeriksaan manual agar tidak dimanipulasi.

6. **Pemantauan.** Dasbor mencatat volume, tingkat karantina, dan laporan kesalahan sehingga penurunan kinerja cepat terdeteksi.


Pemisahan skor ke tiga zona (lolos, peringatan, karantina) merupakan cara praktis mengendalikan *false positive*. Hanya pesan dengan keyakinan sangat tinggi yang otomatis dikarantina, sedangkan kasus abu-abu tetap sampai ke pengguna dengan penanda. Cara ini mengurangi risiko email sah hilang tanpa disadari.

BAB IV

IMPLEMENTASI DAN HASIL

4.1 Persiapan Data

Data dibuat oleh skrip *buat_dataset.py* dengan *random seed* tetap (42) sehingga hasil dapat direproduksi. Hasilnya adalah berkas *emails_sintetis.csv* dengan dua kolom, yakni *teks* dan *label*. Gambar 2 menunjukkan distribusi kelas: spam sekitar sepertiga dari seluruh data. Ketidakseimbangan ini disengaja karena pada praktiknya email sah lebih banyak daripada spam. Pemisahan data latih dan uji memakai *stratified split* agar proporsi kelas tetap terjaga.



Gambar 2. Distribusi kelas pada dataset sintetis

Contoh potongan data disajikan pada Tabel 6.

Tabel 6. Contoh data pada dataset sintetis

Teks email (dipersingkat)	Label
Seminar gratis 'Pengantar Kecerdasan Buatan' terbuka untuk seluruh mahasiswa, Selasa pukul 13.00 ...	ham
Kami mendeteksi login mencurigakan pada akun Anda. Konfirmasi kata sandi Anda di bit.ly/x9Kd2 ...	spam
Silakan hubungi kami bila ada pertanyaan. Dapatkan iPhone terbaru hanya Rp 300.000! Promo kilat ...	spam

4.2 Pra-pemrosesan dan Ekstraksi Fitur

Fungsi *bersihkan()* mengubah teks menjadi huruf kecil, mengganti tautan dengan token *tautan*, mengganti deret angka dengan token *angka*, lalu menghapus

karakter selain huruf. Sebagai contoh, kalimat "Segera verifikasi akun bank Anda di bit.ly/abc123 ..." berubah menjadi "segera verifikasi akun bank anda di tautan ...". Hasil pembersihan kemudian diubah menjadi vektor TF-IDF oleh *TfidfVectorizer* dengan konfigurasi pada Tabel 7, menghasilkan 1.144 fitur.

Tabel 7. Konfigurasi TF-IDF dan pembagian data

Parameter	Nilai	Alasan
ngram_range	(1, 2)	Menangkap kata tunggal dan frasa dua kata
min_df	2	Membuang kata langka yang hanya muncul sekali
sublinear_tf	True	Meredam pengaruh kata yang berulang banyak kali
test_size	0,2 (stratified)	80% latih, 20% uji dengan proporsi kelas terjaga
random_state	42	Hasil dapat direproduksi

4.3 Pelatihan Model


Tiga model dilatih di dalam *Pipeline* scikit-learn yang menggabungkan TF-IDF dan pengklasifikasi, sehingga vektorisasi dipelajari hanya dari data latih dan tidak bocor ke data uji. Hiperparameter yang dipakai: Naive Bayes dengan $\alpha = 0,5$; *Logistic Regression* dengan $C = 3,0$; dan *Linear SVM* dengan $C = 1,0$. Untuk menaksir kestabilan, dilakukan juga *stratified 5-fold cross-validation* pada data latih dengan metrik F1.

4.4 Hasil Evaluasi

Tabel 8 memuat kinerja ketiga model pada 600 email data uji. Hasil menunjukkan ketiga model menghasilkan nilai yang **identik**: akurasi 98,83%, presisi 97,71%, *recall* 99,07%, dan F1 98,38%. Rata-rata F1 hasil *cross-validation* adalah 96,87% dengan simpangan baku 0,74%, juga identik untuk ketiga model.

Tabel 8. Kinerja model pada data uji dan hasil cross-validation

Model	Accuracy	Precision	Recall	F1	CV F1 (rata-rata $\pm$ SD)
Naive Bayes	98,83%	97,71%	99,07%	98,38%	96,87% $\pm$ 0,74%
Logistic Regression	98,83%	97,71%	99,07%	98,38%	96,87% $\pm$ 0,74%
Linear SVM	98,83%	97,71%	99,07%	98,38%	96,87% $\pm$ 0,74%




Gambar 3. Perbandingan metrik ketiga model pada data uji

Nilai yang sama persis pada tiga algoritma berbeda bukan kebetulan yang mencurigakan, melainkan cerminan sifat data. Pola spam dan ham pada data sintetis ini sangat terpisah sehingga ketiga model menemukan batas keputusan yang sama untuk hampir seluruh email. Perbedaan antar-algoritma baru akan tampak pada data nyata yang lebih beragam. Model *Naive Bayes* dipilih sebagai model terbaik karena berada di urutan pertama saat nilai F1 seri, sekaligus paling sederhana dan tercepat dilatih.

4.4.1 Confusion matrix

Gambar 4 menunjukkan *confusion matrix* untuk model Naive Bayes. Dari 600 email uji, 380 ham terdeteksi benar (TN), 213 spam terdeteksi benar (TP), 5 ham keliru dicap spam (FP), dan 2 spam lolos sebagai ham (FN). Total kesalahan adalah 7 email atau 1,17%.




Gambar 4. Confusion matrix model Naive Bayes pada data uji

Tabel 9. Confusion matrix dalam bentuk tabel

	Prediksi ham	Prediksi spam
Aktual ham	380 (TN)	5 (FP)
Aktual spam	2 (FN)	213 (TP)

4.4.2 Kata penciri

Karena model bersifat linear (atau probabilistik berbasis kata), kata dan frasa yang paling berpengaruh dapat ditampilkan. Gambar 5 memperlihatkan penciri terkuat untuk kelas spam dan ham. Kata seperti *akun*, *sekarang*, *hanya*, *terbatas*, dan token *tautan* mendorong prediksi ke arah spam, sedangkan kata bernuansa administrasi akademik seperti *rapat*, *pukul*, *email kampus*, dan *sudah diterima* mendorong ke arah ham. Ini sesuai intuisi: spam bernada mendesak dan mengarahkan pengguna ke tautan, sedangkan email kampus bernada informatif dan menyebut waktu atau tempat.



Gambar 5. Kata dan frasa penciri kelas spam dan ham

Tabel 10. Delapan penciri teratas tiap kelas

Kelas	Delapan penciri teratas
Spam	<i>akun, dalam angka, dalam, sekarang, di tautan, hanya, terbatas, tautan</i>
Ham	<i>kamis, rapat, kamis pukul, pukul, pukul angka, email kampus, milik, sudah diterima</i>

4.5 Analisis Kesalahan

Total 7 email salah diklasifikasikan. Setelah diperiksa satu per satu, seluruhnya ternyata merupakan email yang **labelnya keliru** akibat noise label 2% yang sengaja disisipkan. Lima di antaranya adalah teks spam yang jelas (misalnya penawaran obat herbal dengan diskon, pinjaman online, dan investasi kripto) tetapi berlabel ham; dua lainnya adalah email kampus sah (pengumuman verifikasi KRS dan seminar gratis) yang berlabel spam. Dalam arti tertentu, model justru "benar" dan labelnya yang salah.

Temuan ini memberi dua pelajaran penting. Pertama, batas atas kinerja pada data ini ditentukan oleh kualitas label, bukan kecanggihan algoritma. Kedua, pada penerapan nyata, daftar email yang diprediksi berbeda dari labelnya adalah alat yang efektif untuk menemukan kesalahan pelabelan dan memperbaiki data (*data cleaning*).

4.6 Demonstrasi Prediksi Email Baru

Model terlatih diuji pada lima email yang tidak ada dalam dataset. Hasilnya tercantum pada Tabel 11. Seluruh prediksi sesuai harapan, termasuk email sah yang memuat kata "gratis" (seminar keamanan siber) yang tetap diklasifikasikan sebagai ham.

Tabel 11. Hasil prediksi pada email baru

Teks email uji	Prediksi	Peluang spam
Segera verifikasi akun bank Anda di bit.ly/abc123 atau akun diblokir hari ini!	SPAM	99,98%
Yth. mahasiswa, jadwal ujian akhir Kecerdasan Buatan sudah tersedia di portal akademik.	HAM	0,01%
Selamat Anda menang undian Rp 50.000.000, kirim data rekening untuk klaim hadiah.	SPAM	100,00%
Tiket layanan #4521 terkait WiFi kampus sedang diproses oleh tim TI.	HAM	0,00%
Seminar gratis keamanan siber untuk mahasiswa, daftar melalui himpunan.	HAM	0,67%

4.7 Diskusi Hasil dan Ancaman terhadap Validitas

Angka kinerja di atas tidak boleh dibaca sebagai klaim bahwa sistem serupa akan mencapai akurasi sekitar 99% pada email kampus nyata. Beberapa alasan perlu diperhatikan.

1. **Data sintetis berbasis templat.** Email dibangkitkan dari 22 templat dengan kata pengisi acak, sehingga variasinya jauh lebih sempit daripada email nyata. Model sangat mudah "menghafal" templat.
2. **Tidak ada adversarial.** Pengirim spam sungguhan berusaha menghindari penyaring, misalnya dengan mengganti huruf ("g4ratis"), menyisipkan spasi, atau menaruh teks di dalam gambar.
3. **Bahasa campuran.** Email nyata sering bercampur bahasa Indonesia, Inggris, dan singkatan tidak baku yang tidak tercakup pada data demonstrasi.
4. **Pergeseran data (*concept drift*).** Modus spam berubah cepat; model perlu dievaluasi dan dilatih ulang secara berkala.

5. **Pemisahan acak.** Data uji berasal dari templat yang sama dengan data latih. Evaluasi yang lebih jujur memerlukan data uji dari sumber atau periode waktu berbeda.

Untuk mendapat gambaran lebih realistis, notebook menyediakan sel opsional yang memakai dataset publik *SMS Spam Collection* (Almeida dkk., 2011). Dataset tersebut berbahasa Inggris dan berupa SMS, tetapi merupakan pesan nyata sehingga hasilnya lebih menggambarkan kesulitan sesungguhnya. Sel tersebut tidak dijalankan dalam penyusunan laporan ini.


4.8 Eksperimen Tambahan

4.8.1 Pengaruh ambang batas keputusan

Pada penerapan nyata, ambang batas peluang spam menentukan keseimbangan antara spam yang tertangkap dan email sah yang terkarantina. Model *Logistic Regression* menghasilkan peluang sehingga ambang batas dapat diubah. Tabel 12 memuat hasil pada data uji yang sama dengan ambang batas berbeda.

Tabel 12. Pengaruh ambang batas peluang spam (Logistic Regression, 600 email uji)

Ambang batas	Precision	Recall	FP	FN
0,50	97,71%	99,07%	5	2
0,90	97,71%	99,07%	5	2
0,95	97,49%	90,23%	5	21
0,96	97,01%	75,35%	5	53
0,97	96,59%	39,53%	3	130
0,98	97,92%	21,86%	1	168




Gambar 6. Precision dan recall pada berbagai ambang batas

Dua hal menarik terlihat. Pertama, untuk ambang 0,5 hingga 0,9 hasilnya tidak berubah karena peluang spam yang diberikan model untuk email spam terkonsentrasi pada kisaran sekitar 0,94 hingga 0,99, sedangkan email ham umumnya berada di bawah 0,1. Kedua, begitu ambang batas dinaikkan mendekati kisaran peluang spam tersebut, *recall* turun tajam: pada ambang 0,97 hanya sekitar 39,5% spam yang tertangkap dan pada 0,98 tinggal sekitar 21,9%. Sementara itu, jumlah FP hanya berkurang dari 5 menjadi 1 pada ambang 0,98. Artinya, menaikkan ambang batas untuk menekan *false positive* pada model ini tidak efisien, karena harganya adalah banyak spam yang lolos. Perlu diingat pula bahwa FP pada data ini pada dasarnya adalah label yang keliru, bukan kesalahan model sejati.

4.8.2 Kurva belajar

Kurva belajar memperlihatkan bagaimana F1 pada data uji berubah menurut jumlah data latih. Naive Bayes dilatih ulang pada sub-sampel acak data latih dengan lima kali pengulangan pada setiap ukuran. Hasilnya terlihat pada Gambar 7.



Gambar 7. Kurva belajar Naive Bayes: F1 terhadap jumlah data latih

Dengan hanya 48 email latih, F1 rata-rata baru 90,45% dan variasinya besar (simpangan baku 6,07%). Pada 120 email, F1 sudah mencapai 98,29%, dan pada 240 email atau lebih nilainya mendatar di 98,38%. Dataran ini menunjukkan bahwa pada data sintetis yang sederhana, menambah data tidak lagi memperbaiki hasil setelah beberapa ratus contoh; sisa kesalahan berasal dari label yang keliru. Pada email nyata yang jauh lebih beragam, kurva serupa diperkirakan naik lebih lambat dan baru mendatar pada jumlah data yang jauh lebih besar; hal ini perlu dibuktikan dengan data nyata.

4.9 Rencana Pengembangan

- Menggunakan email nyata yang telah dianonimkan dan disetujui pemiliknya, dengan pembagian data berdasarkan waktu.
- Menambah fitur non-teks: reputasi domain pengirim, jumlah dan jenis tautan, ada tidaknya lampiran, serta hasil autentikasi SPF, DKIM, dan DMARC.
- Mencoba model berbasis *embedding* kalimat atau model bahasa terlatih untuk menangani variasi bahasa.
- Menyetel ambang batas peluang agar *false positive* minimal, disertai antarmuka peninjauan karantina bagi pengguna.
- Membangun mekanisme umpan balik: setiap koreksi pengguna dipakai untuk pelatihan ulang berkala.

BAB V

PEMBAHASAN MANFAAT, KETERBATASAN, DAN RISIKO ETIKA/PRIVASI

5.1 Manfaat

Tabel 13. Manfaat penerapan sistem deteksi spam berbasis machine learning

Pihak	Manfaat
Mahasiswa dan staf	Kotak masuk lebih bersih, risiko tertipu phishing berkurang, informasi penting lebih mudah ditemukan.
Tim layanan TI	Beban penanganan laporan email mencurigakan berkurang; aturan penyaring tidak perlu ditulis manual terus-menerus.
Institusi	Menurunkan risiko pengambilalihan akun, kebocoran data, dan insiden keamanan yang merusak reputasi.
Infrastruktur	Berkurangnya lalu lintas dan penyimpanan untuk pesan yang tidak perlu.

5.2 Keterbatasan

- **Kesalahan tidak terhindarkan.** Model bersifat probabilistik; selalu ada spam yang lolos dan email sah yang terjebak.
- **Ketergantungan pada data.** Data latih yang tidak mewakili, bias, atau berlabel keliru menghasilkan model yang menyesatkan, seperti terlihat pada analisis kesalahan (Subbab 4.5).
- **Representasi kata sederhana.** TF-IDF tidak memahami konteks dan makna; kalimat yang disusun cerdas dapat mengecoh model.
- **Mudah ditantang penyerang.** Pelaku spam dapat mempelajari dan menghindari pola yang dideteksi.
- **Butuh pemeliharaan.** Kinerja menurun seiring waktu bila model tidak dilatih ulang.
- **Cakupan terbatas.** Prototipe hanya menganalisis teks, bukan lampiran, gambar, maupun metadata pengirim.
- **Bukti terbatas.** Hasil pada laporan ini berasal dari data sintetis, sehingga belum membuktikan kinerja pada email nyata.

5.3 Risiko Etika dan Privasi

Pendeteksi spam harus membaca isi email, dan di situlah risiko etika dan privasi utamanya. Tabel 14 merangkum risiko utama disertai upaya mitigasinya.

Tabel 14. Risiko etika dan privasi beserta mitigasinya

Risiko	Uraian	Mitigasi
Privasi isi email	Pemrosesan teks pribadi dapat membuka informasi sensitif kepada operator atau tersimpan tanpa batas waktu.	Minimisasi data, pemrosesan di server kampus, kontrol akses ketat, retensi terbatas, pengaturan sesuai UU PDP.
False positive	Email sah (tagihan, beasiswa, pengumuman ujian) masuk karantina dan pengguna dirugikan.	Karantina, bukan penghapusan; notifikasi ringkas; ambang batas konservatif; jalur pelaporan cepat.
Bias	Gaya bahasa tertentu (dialek, campur kode, bahasa asing) lebih sering dianggap spam sehingga sebagian pengguna dirugikan.	Uji kinerja per kelompok bahasa dan unit; perbanyak variasi data latih.
Transparansi	Pengguna tidak tahu mengapa emailnya diblokir.	Tampilkan alasan singkat (kata penciri) dan kebijakan yang mudah diakses.
Akuntabilitas	Tidak jelas siapa bertanggung jawab atas keputusan otomatis yang keliru.	Tetapkan penanggung jawab, catatan audit, dan pengawasan manusia.
Penyalahgunaan	Kemampuan membaca dan mengklasifikasi email dapat dipakai untuk pengawasan di luar tujuan penyaringan spam.	Batasi tujuan pemrosesan secara tertulis dan audit berkala.
Keamanan model dan data	Data latih atau model dapat bocor atau dimanipulasi (misalnya diracuni dengan label palsu).	Enkripsi, pembatasan hak akses, validasi sumber label.

5.4 Prinsip Penerapan yang Bertanggung Jawab

1. **Pengawasan manusia.** Keputusan otomatis berdampak tinggi harus dapat ditinjau dan dibatalkan oleh manusia.
2. **Pembatasan tujuan.** Data email hanya diproses untuk tujuan keamanan dan penyaringan spam, dengan pemberitahuan yang jelas kepada pengguna.

3. **Minimisasi dan anonimisasi.** Data latih sebaiknya dianonimkan; bila memungkinkan hanya fitur turunan yang disimpan, bukan isi email lengkap.
4. **Evaluasi berkelanjutan.** Kinerja dipantau, khususnya tingkat *false positive*, dan model diperbarui berkala.
5. **Kejelasan komunikasi.** Pengguna diberi tahu bahwa email disaring secara otomatis dan bagaimana cara melaporkan kesalahan.

BAB VI

PENUTUP

6.1 Kesimpulan

1. *Machine learning* merupakan bidang AI yang sesuai untuk deteksi spam email karena pola spam sulit dirumuskan sebagai aturan tetap, data berlabel mudah diperoleh, dan pola tersebut terus berubah sehingga model perlu belajar dari data.
2. Alur kerja lengkap telah dirancang dan diimplementasikan: pembersihan teks, ekstraksi fitur TF-IDF (unigram dan bigram), pelatihan tiga model, dan evaluasi.
3. Pada 600 email uji sintetis, model mencapai akurasi 98,83%, presisi 97,71%, *recall* 99,07%, dan F1 98,38%. Ketiga algoritma menghasilkan nilai yang sama, dan seluruh kesalahan berasal dari label yang sengaja dikacaukan.
4. Angka tersebut tidak dapat digeneralisasi ke email nyata karena data bersifat sintetis dan berbasis templat. Penerapan sungguhan memerlukan data nyata, evaluasi berbasis waktu, serta pemeliharaan berkelanjutan.
5. Penerapan sistem perlu memperhatikan risiko privasi, *false positive*, bias, dan transparansi, dengan mitigasi berupa karantina, pengawasan manusia, pembatasan tujuan, dan kepatuhan pada UU Pelindungan Data Pribadi.

6.2 Saran

- Mengganti data sintetis dengan data email nyata yang dianonimkan dan disetujui, serta mengevaluasi model pada data periode berbeda.
- Memperkaya fitur dengan metadata pengirim dan hasil autentikasi domain.
- Membandingkan dengan model berbasis *embedding* atau model bahasa terlatih pada teks berbahasa campuran.
- Menerapkan pemantauan berkala dan proses pelatihan ulang, disertai antarmuka peninjauan karantina bagi pengguna.
- Menyusun kebijakan penggunaan data yang jelas sebelum sistem dipakai pada layanan email institusi.

DAFTAR PUSTAKA

- Almeida, T. A., Gómez Hidalgo, J. M., & Yamakami, A. (2011). Contributions to the study of SMS spam filtering: New collection and results. *Proceedings of the 11th ACM Symposium on Document Engineering*, 259–262.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Pedregosa, F., dkk. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Republik Indonesia. (2022). *Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi*.
- Russell, S., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- Sahami, M., Dumais, S., Heckerman, D., & Horvitz, E. (1998). A Bayesian approach to filtering junk e-mail. *AAAI-98 Workshop on Learning for Text Categorization*.

LAMPIRAN

Lampiran 1. Tautan Proyek

Kode sumber, notebook, data, laporan, dan slide dapat diakses pada repositori GitHub: [tempel tautan GitHub proyek di sini].

Lampiran 2. Struktur Repositori

```
deteksi-spam-email/  
+-- README.md  
+-- data/  
|   +-- emails_sintetis.csv  
+-- src/  
|   +-- buat_dataset.py          # pembangkit dataset sintetis  
|   +-- deteksi_spam.py         # pipeline latih dan evaluasi  
+-- notebook/  
|   +-- deteksi_spam_email.ipynb  
+-- laporan/  
|   +-- Laporan_Deteksi_Spam_Email.pdf  
+-- slide/  
    +-- Slide_Deteksi_Spam_Email.pptx
```

Lampiran 3. Kode Pembangkit Dataset (buat_dataset.py)

```
"""Membuat dataset email sintetis berbahasa Indonesia (spam vs ham) untuk demo.  
Dataset dibuat dari templat + kalimat pengisi acak, dengan sengaja memuat kasus sulit  
(email sah yang memakai kata 'gratis', 'diskon', 'verifikasi', 'segera') serta  
sedikit noise label agar evaluasi model tidak terlalu ideal.  
"""  
import random, csv, os  
random.seed(42)  
  
nama = ["Andi", "Budi", "Citra", "Dewi", "Eka", "Fajar", "Gita", "Hendra", "Intan", "Joko", "Kiran",  
        "Lukman", "Maya", "Nadia", "Ok", "Putri", "Rangga", "Sari", "Tono", "Wulan"]  
kota = ["Bandar Lampung", "Jakarta", "Bandung", "Surabaya", "Yogyakarta", "Medan", "Semarang",  
        "Makassar"]  
bank = ["BCA", "BRI", "BNI", "Mandiri", "BSI", "CIMB"]  
matkul = ["Basis Data", "Jaringan Komputer", "Pemrograman Web", "Sistem Operasi", "Kecerdasan  
        Buatan", "Rekayasa Perangkat Lunak", "Statistika", "Keamanan Informasi"]  
hari = ["Senin", "Selasa", "Rabu", "Kamis", "Jumat"]  
layanan = ["WiFi kampus", "portal akademik", "email kampus", "VPN", "server lab", "printer pe  
        rpustakaan", "aplikasi presensi"]  
domain_spam = ["bit.ly/x9Kd2", "tinyurl.com/promo88", "klik-akun-aman.xyz", "hadiah-nasiona  
        l.Top", "cek-saldo-bank.online"]  
angka = lambda a,b: random.randint(a,b)  
  
filler_netral = [  
    "Terima kasih atas perhatiannya.", "Mohon dicek kembali informasi berikut.", "Salam horma  
        t.", "Silakan hubungi kami bila ada pertanyaan.",  
    "Informasi ini dikirim otomatis, mohon tidak membalas email ini.", "Harap segera meninda  
        klanjuti sesuai kebutuhan.",  
    "Kami tunggu konfirmasi Anda.", "Semoga sehat selalu.", "Mohon maaf atas ketidaknyamanann  
        ya."]  
  
def spam():  
    t = random.choice(range(10))  
    if t==0:  
        s=f"PERINGATAN! Akun {random.choice(bank)} Anda akan diblokir dalam 24 jam. Sege  
        ra verifikasi data di {random.  
        choice(domain_spam)} untuk menghindari pemblokiran."  
    elif t==1:  
        s=f"Selamat! Anda terpilih sebagai pemenang undian hadiah Rp {angka(10,500)}.000  
        .000. Klik {random.choice(doma  
        in_spam)} dan kirim data rekening untuk klaim hadiah gratis."  
    elif t==2:  
        s=f"Butuh dana cepat? Pinjaman online cair {angka(5,30)} menit tanpa jaminan, ta  
        npa survei. Bunga rendah, daft  
        ar sekarang di {random.choice(domain_spam)}."  
    elif t==3:  
        s=f"Bonus deposit {angka(50,300)}% untuk member baru! Situs slot gacor resmi, me  
        nang mudah setiap hari. Daftar  
        gratis di {random.choice(domain_spam)}."  
    elif t==4:  
        s=f"Investasi kripto untung {angka(10,90)}% per minggu, dijamin tanpa risiko. Tr  
        ansfer sekarang, kuota terbatas  
        s! Hubungi WhatsApp admin."  
    elif t==5:  
        s=f"Lowongan kerja online dari rumah, gaji Rp {angka(3,15)} juta per bulan tanpa  
        pengalaman. Cukup bayar biaya  
        pendaftaran dan kirim KTP Anda."  
    elif t==6:  
        s=f"Paket Anda tertahan di bea cukai. Bayar biaya administrasi Rp {angka(15,90)}  
        .000 hari ini via {random.choi  
        ce(domain_spam)} agar paket segera dikirim."  
    elif t==7:
```

```

        s=f"Obat herbal ampuh, hasil dalam {angka(3,14)} hari, diskon {angka(50,80)}% ha
nya hari ini! Pesan sekarang,
stok terbatas, gratis ongkir."
    elif t==8:
        s=f"Kami mendeteksi login mencurigakan pada akun Anda. Konfirmasi kata sandi And
a di {random.choice(domain spa
m)} sekarang juga atau akun ditutup permanen."
    else:
        s=f"Dapatkan iPhone terbaru hanya Rp {angka(1,3)}00.000! Promo kilat, klik link
berikut dan isi data diri Anda
untuk mendapatkannya gratis."
        if random.random()<0.35:
            s=random.choice(filler_netral)+" "+s
        return s

def ham():
    t = random.choice(range(12))
    n = random.choice(nama)
    if t==0:
        s=f"Yth. mahasiswa, ujian tengah semester mata kuliah {random.choice(matkul)} di
laksanakan hari {random.choice
(hari)} pukul {angka(7,14)}.00 di ruang {angka(101,320)}."
    elif t==1:
        s=f"Halo {n}, tiket layanan #{angka(1000,9999)} terkait {random.choice(layanan)}
sudah kami terima dan sedang
diproses oleh tim TI. Estimasi selesai {angka(1,3)} hari kerja."
    elif t==2:
        s=f"Dear {n}, mohon kumpulkan tugas {random.choice(matkul)} melalui portal akade
mik paling lambat hari {random
.choice(hari)}. Terima kasih."
    elif t==3:
        s=f"Undangan rapat koordinasi program studi hari {random.choice(hari)} pukul {an
gka(8,15)}.00 di ruang rapat.
Mohon konfirmasi kehadiran."
    elif t==4:
        s=f"Bagi mahasiswa yang belum melakukan verifikasi KRS, silakan segera verifikas
i melalui portal akademik resm
i sebelum batas waktu hari {random.choice(hari)}."
    elif t==5:
        s=f"Seminar gratis 'Pengantar Kecerdasan Buatan' terbuka untuk seluruh mahasiswa
, {random.choice(hari)} pukul
{angka(9,15)}.00. Pendaftaran gratis melalui himpunan mahasiswa."
    elif t==6:
        s=f"Toko buku kampus memberi diskon {angka(10,25)}% untuk buku teks {random.choi
ce(matkul)} sampai akhir bulan
. Tunjukkan kartu mahasiswa saat pembelian."
    elif t==7:
        s=f"Hai {n}, jadi kita belajar bareng untuk ujian {random.choice(matkul)} di per
ustakaan hari {random.choice(
hari)}? Kabar ya."
    elif t==8:
        s=f"Pemberitahuan pemeliharaan: {random.choice(layanan)} tidak dapat diakses pad
a {random.choice(hari)} pukul
{angka(0,4)}.00 sampai {angka(5,7)}.00 WIB. Mohon maaf atas ketidaknyamanannya."
    elif t==9:
        s=f"Pembayaran UKT semester ini dapat dilakukan melalui bank {random.choice(bank
)} resmi kampus sampai tanggal
{angka(5,28)}. Bukti bayar diunggah di portal akademik."
    elif t==10:
        s=f"Notifikasi keamanan: kata sandi email kampus Anda berhasil diubah. Bila buka
n Anda, segera hubungi helpdes
k TI di gedung {random.choice('ABCD')} lantai {angka(1,3)}."
    else:
        s=f"Laporan praktikum {random.choice(matkul)} milik {n} sudah diterima. Nilai ak
an diumumkan di {random.choice
(kota)} pada pertemuan berikutnya."
        if random.random()<0.35:
            s=s+" "+random.choice(filler_netral)
        return s

rows=[(spam(),"spam") for _ in range(1050)]+[(ham(),"ham") for _ in range(1950)]
random.shuffle(rows)
for i in range(int(0.02*len(rows))): # noise label 2%
    t,l=rows[i]; rows[i]=(t,"ham" if l=="spam" else "spam")
random.shuffle(rows)

os.makedirs("data",exist_ok=True)
with open("data/emails_sIntetis.csv","w",newline="",encoding="utf-8") as f:
    w=csv.writer(f); w.writerow(["teks","label"]); w.writerows(rows)
print("Selesai:",len(rows),"baris")

```

Lampiran 4. Kode Pelatihan dan Evaluasi (deteksi_spam.py)

```

"""Pipeline deteksi spam email: TF-IDF + (Naive Bayes | Logistic Regression | Linear SVM
)"""
import re, json, numpy as np, pandas as pd
import matplotlib; matplotlib.use("Agg")
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split, cross_val_score, StratifiedKFold
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.pipeline import Pipeline
from sklearn.naive_bayes import MultinomialNB
from sklearn.linear_model import LogisticRegression
from sklearn.svm import LinearSVC
from sklearn.metrics import (accuracy_score, precision_score, recall_score, f1_score,
                             confusion_matrix, classification_report, ConfusionMatrixDis
play)

def bersihkan(t):
    t = t.lower()
    t = re.sub(r"https?://\S+|\b\S+\. (com|xyz|top|online)\S*|bit\.ly/\S+", " tautan ", t
    )
    t = re.sub(r"\d+", " angka ", t)
    t = re.sub(r"[^a-z\s]", " ", t)

```

```

        return re.sub(r"\s+", " ", t).strip()

df = pd.read_csv("data/emails_sintetis.csv")
df["bersih"] = df["teks"].apply(bersihkan)
y = (df["label"] == "spam").astype(int)
Xtr, Xte, ytr, yte, tr_idx, te_idx = train_test_split(df["bersih"], y, df.index, test_size=0.2, stratify=y, random_state=42)

def pipa(clf):
    return Pipeline([("tfidf", TfidfVectorizer(ngram_range=(1,2), min_df=2, sublinear_tf=True)), ("clf", clf)])

model = {"Naive Bayes": MultinomialNB(alpha=0.5),
         "Logistic Regression": LogisticRegression(max_iter=1000, C=3.0),
         "Linear SVM": LinearSVC(C=1.0)}
hasil, cv = {}, {}
skf = StratifiedKFold(5, shuffle=True, random_state=42)
terlatih = {}
for nm, clf in model.items():
    p = pipa(clf).fit(Xtr, ytr); terlatih[nm] = p
    pr = p.predict(Xte)
    hasil[nm] = dict(accuracy=accuracy_score(yte, pr), precision=precision_score(yte, pr),
                    recall=recall_score(yte, pr), f1=f1_score(yte, pr))
    s = cross_val_score(pipa(clf), Xtr, ytr, cv=skf, scoring="f1")
    cv[nm] = dict(mean=float(s.mean()), std=float(s.std()))

terbaik = max(hasil, key=lambda k: hasil[k]["f1"])
p = terlatih[terbaik]; pred = p.predict(Xte)
cm = confusion_matrix(yte, pred)

# Fitur paling berpengaruh (model linear)
feat = p.named_steps["tfidf"].get_feature_names_out()
clf = p.named_steps["clf"]
if hasattr(clf, "coef"): w = clf.coef_[0]
else: w = clf.feature_log_prob_[1] - clf.feature_log_prob_[0]
top_spam = [(feat[i], float(w[i])) for i in np.argsort(w)[-12:][::-1]]
top_ham = [(feat[i], float(w[i])) for i in np.argsort(w)[:12]]

# Analisis kesalahan
salah = te_idx[pred != yte.values]
err = df.loc[salah, ["teks", "label"]].head(8).to_dict("records")

# Contoh prediksi
contoh = ["Segera verifikasi akun bank Anda di bit.ly/abc123 atau akun diblokir hari ini!",
          "Yth. mahasiswa, jadwal ujian akhir Kecerdasan Buatan sudah tersedia di portal akademik.",
          "Selamat Anda menang undian Rp 50.000.000, kirim data rekening untuk klaim hadiah.",
          "Tiket layanan #4521 terkait WiFi kampus sedang diproses oleh tim TI.",
          "Seminar gratis keamanan siber untuk mahasiswa, daftar melalui himpunan."]
prob = None
if hasattr(clf, "predict_proba"): prob = p.predict_proba([bersihkan(c) for c in contoh])[:, 1]
pc = p.predict([bersihkan(c) for c in contoh])
pred_contoh = [dict(teks=c, prediksi="spam" if k else "ham", prob=float(prob[i]) if prob is not None else None) for i, (c, k) in enumerate(zip(contoh, pc))]

out = dict(n=len(df), n_spam=int(y.sum()), n_ham=int((1-y).sum()), n_train=len(Xtr), n_test=len(Xte),
           hasil=hasil, cv=cv, terbaik=terbaik, cm=cm.tolist(), top_spam=top_spam, top_ham=top_ham,
           err=err, contoh=pred_contoh, n_fitur=len(feat),
           panjang_rata=float(df["teks"].str.split().str.len().mean()))
json.dump(out, open("laporan/hasil.json", "w"), ensure_ascii=False, indent=1)

# ----- Gambar -----
plt.rcParams.update({"font.size": 10, "axes.spines.top": False, "axes.spines.right": False})
fig, ax = plt.subplots(figsize=(4.6, 3.4))
ax.bar(["Ham", "Spam"], [out["n_ham"], out["n_spam"]], color=["#4C78A8", "#E45756"])
for i, v in enumerate([out["n_ham"], out["n_spam"]]): ax.text(i, v + 25, str(v), ha="center")
ax.set_ylabel("Jumlah email"); ax.set_title("Distribusi kelas dataset"); plt.tight_layout()
plt.savefig("laporan/gambar/distribusi.png", dpi=200); plt.close()

fig, ax = plt.subplots(figsize=(4.2, 3.6))
ConfusionMatrixDisplay(cm, display_labels=["Ham", "Spam"]).plot(ax=ax, cmap="Blues", colorbar=False)
ax.set_title(f"Confusion matrix - {terbaik}"); plt.tight_layout()
plt.savefig("laporan/gambar/confusion.png", dpi=200); plt.close()

fig, ax = plt.subplots(figsize=(6.4, 3.4))
mets = ["accuracy", "precision", "recall", "f1"]; x = np.arange(len(mets)); wd = 0.26
for i, (nm, r) in enumerate(hasil.items()):
    ax.bar(x + (i - 1) * wd, [r[m] for m in mets], wd, label=nm)
ax.set_xticks(x); ax.set_xticklabels([m.capitalize() for m in mets]); ax.set_ylim(0.8, 1.02)
ax.legend(loc="lower right", fontsize=8); ax.set_title("Perbandingan metrik pada data uji"); plt.tight_layout()
plt.savefig("laporan/gambar/metrik.png", dpi=200); plt.close()

fig, axs = plt.subplots(1, 2, figsize=(7, 3.6))
for a, dat, col, ttl in [(axs[0], top_spam[:10][::-1], "#E45756", "Penciri spam"), (axs[1], top_ham[:10], "#4C78A8", "Penciri ham")]:
    a.barh([d[0] for d in dat], [abs(d[1]) for d in dat], color=col); a.set_title(ttl); a.tick_params(labelsize=8)
plt.tight_layout(); plt.savefig("laporan/gambar/fitur.png", dpi=200); plt.close()

# Diagram alur
fig, ax = plt.subplots(figsize=(7.2, 2.6)); ax.axis("off")
kotak = ["Email\ndmasuk", "Pembersihan\nteks", "TF-IDF\n(unigram+bigram)", "Model\nklasifikasi"]

```

```

        ikasi", "Skor\nspam", "Ham / S
        pam\n(karantina)"]
for i, k in enumerate(kotak):
    ax.text(i, 0, k, ha="center", va="center", fontsize=8.5, bbox=dict(boxstyle="round,p
    ad=0.5", fc="#EAF1FB" if i not
        in (0, 5) else "#FDECEA", ec="#5555"))
    if i < len(kotak) - 1: ax.annotate("", xy=(i + 0.62, 0), xytext=(i + 0.38, 0), arrow
    props=dict(arrowstyle="->", co
        lor="#333"))
ax.set_xlim(-0.6, 5.6); ax.set_ylim(-0.5, 0.5); plt.tight_layout()
plt.savefig("laporan/gambar/alur.png", dpi=200); plt.close()

print(json.dumps({k: out[k] for k in ["hasil", "cv", "terbaik", "cm", "n_fitur", "panjan
    g_rata"]}, indent=1))
print("TOP SPAM", top_spam[:8]); print("TOP HAM", top_ham[:8])
for e in err: print("ERR", e["label"], "|", e["teks"][:110])
print(pred_contoh)

```

Lampiran 5. Glosarium

Tabel 15. Daftar istilah

Istilah	Arti
Spam	Pesan yang tidak diminta dan dikirim massal, sering berisi penipuan atau iklan.
Ham	Email sah yang bukan spam.
Phishing	Penipuan yang menyamar sebagai pihak tepercaya untuk mencuri data pribadi.
Supervised learning	Pembelajaran dari data yang sudah diberi label.
Fitur	Ciri terukur yang dipakai model, misalnya bobot TF-IDF sebuah kata.
N-gram	Rangkaian n kata berurutan, misalnya bigram berarti dua kata berurutan.
TF-IDF	Pembobotan kata berdasarkan frekuensi dalam dokumen dan kelangkaannya dalam koleksi.
Confusion matrix	Tabel jumlah prediksi benar dan salah untuk setiap kelas.
False positive	Email sah yang salah dinyatakan spam.
False negative	Spam yang salah dinyatakan sebagai email sah.
Cross-validation	Teknik evaluasi dengan membagi data menjadi beberapa lipatan yang bergiliran menjadi data uji.
Concept drift	Perubahan pola data dari waktu ke waktu yang menurunkan kinerja model.
Data leakage	Kebocoran informasi data uji ke proses pelatihan sehingga evaluasi terlalu optimistis.
Noise label	Label yang keliru pada data, misalnya akibat kesalahan pelabelan.
Karantina	Folder penampung sementara email yang dicurigai spam sebelum dihapus atau dipulihkan.